

Trabajo Práctico Final ASSD


Algoritmos adaptativos aplicados a ANC

Linares Gonzalo Ezequiel
Gullino Agustin Luis
Bustelo Nicolás
Sergi Damián
Feldman Santiago

INSTITUTO TECNOLÓGICO DE BUENOS AIRES

Diciembre 2023


Introducción



Aplicaciones




Descenso por gradiente




Descenso por gradiente


Small learning rate



Large learning rate



Filtro de Wiener



$$e(n) = d(n) - \hat{d}(n) = d(n) - \vec{\mathbf{w}} * \vec{\mathbf{x}}(n)$$

$$\vec{\mathbf{x}}(n) = [x(n) \quad x(n-1) \quad \dots \quad x(n-M+1)]^T$$

$$\vec{\mathbf{w}} = [w_0 \quad w_1 \quad \dots \quad w_{M-1}]$$

Filtro de Wiener

Para obtener el filtro \mathbf{w} óptimo en el sentido del MSE:

$$J(\vec{\mathbf{w}}) = \mathbb{E}\{e^2(n)\} = \mathbb{E}\{(d(n) - \vec{\mathbf{w}} * \vec{\mathbf{x}}(n))^2\}$$

$$\nabla J(\vec{\mathbf{w}}) = \mathbb{E}\{-2 * \vec{\mathbf{x}}(n) * (d(n) - \vec{\mathbf{w}} * \vec{\mathbf{x}}(n))\}$$

$$\nabla J(\vec{\mathbf{w}}) = 0 \Rightarrow \mathbb{E}\{\vec{\mathbf{x}}(n) * d(n)\} = \mathbb{E}\{\vec{\mathbf{x}}(n) * \vec{\mathbf{x}}(n) * \vec{\mathbf{w}}\}$$

$$\mathbf{R} * \vec{\mathbf{w}} = \mathbf{p}$$

Filtro de Wiener + SGD

$$J(\vec{\mathbf{w}}) = \mathbb{E}\{e^2(n)\}$$


$$J(\vec{\mathbf{w}}) = \mathbb{E}\{(\vec{d}(n) - \vec{\mathbf{w}} * \vec{\mathbf{x}})^2\}$$

$$\nabla J(\vec{\mathbf{w}}) = -\mathbb{E}\{2 * \vec{\mathbf{x}} * (d(n) - \vec{\mathbf{w}} * \vec{\mathbf{x}})\}$$

$$\nabla J(\vec{\mathbf{w}}) = \mathbb{E}\{-2 * \vec{\mathbf{x}} * e(n)\}$$

$$\vec{\mathbf{w}}(n+1) = \vec{\mathbf{w}}(n) - \frac{1}{2} * \mu * \nabla J(\vec{\mathbf{w}}(n))$$

$$\vec{\mathbf{w}}(n+1) = \vec{\mathbf{w}}(n) + \mu * \mathbb{E}\{e(n) * \vec{\mathbf{x}}(n)\}$$



Filtro de Wiener + SGD - Convergencia

Si bien en el algoritmo de SGD se inicializan arbitrariamente los pesos del vector, en general se hacen en 0 y para converger (sin convergencia alternada) se tiene que cumplir la condición:

$$0 < \mu < 1/\lambda_{MAX}$$

Siendo λ_{MAX} el mayor autovalor de la matriz de correlación R .

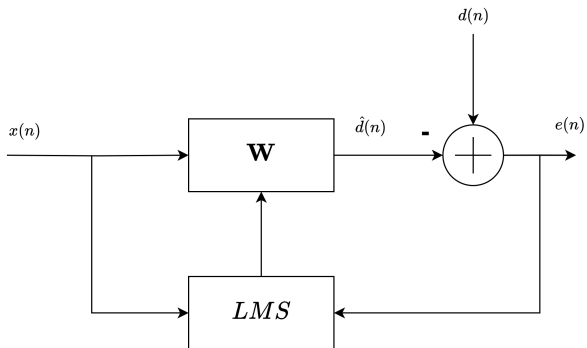
LMS

Dada la ecuación de actualización de $\vec{w}(n)$ obtenida al realizar SGD sobre filtrado óptimo, se puede obtener *LMS* estimando el valor esperado en la expresión de actualización. En particular, *LMS* clásico se obtiene de aproximar el valor esperado del producto por el producto:

$$\vec{w}(n+1) = \vec{w}(n) + \mu * \mathbb{E}\{e(n) * \vec{x}(n)\} \approx$$

$$\vec{w}(n+1) = \vec{w}(n) + \mu * e(n) * \vec{x}(n)$$

LMS



LMS - Algoritmo: Resumen

Parámetros:

$M = \text{orden del filtro}$

$\mu = \text{paso del algoritmo}$

Inicialización:

$w(0) = \mathbf{0}$

Cálculo:



For $n = 0, 1, 2, \dots$

$$\vec{x}(n) = [x(n), x(n-1), \dots, x(n-M+1)]^T$$

$$e(n) = d(n) - \vec{w}(n)\vec{x}(n)$$

$$\vec{w}(n+1) = \vec{w}(n) + \mu e(n)\vec{x}(n)$$

Sistema físico



FxLMS




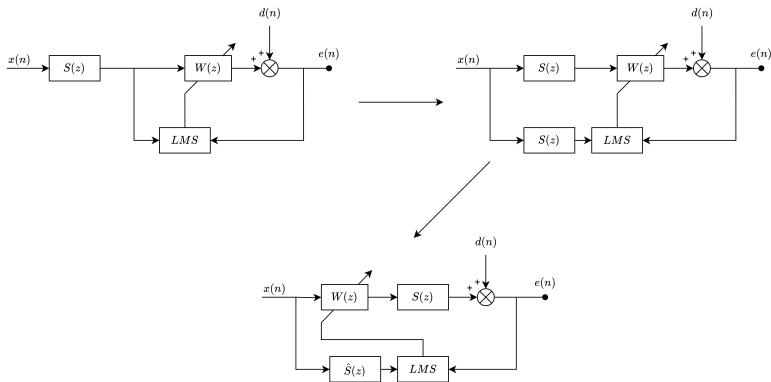
Diagrama de bloques del sistema

$$W(z) = -\frac{P(z)}{S(z)}$$


$$w(n+1) = w(n) - \mu x_f(n)e(n)$$

¹Imágenes obtenidas del paper *Stochastic Analysis of the Filtered-x LMS Algorithm for Active Noise Control*

FxLMS



RLS



Initialization

$$\mathbf{w}(-1) = \mathbf{0} \quad \mathbf{P}(-1) = \delta^{-1} \mathbf{I}$$

$\delta = \text{small positive constant}$

For each $n = 0, 1, 2, \dots$ compute:

Adaptation gain computation

$$\bar{\mathbf{g}}(n) = \lambda^{-1} \mathbf{P}(n-1) \mathbf{x}(n)$$

$$\bar{\alpha}(n) = 1 + \bar{\mathbf{g}}^H(n) \mathbf{x}(n)$$

$$\mathbf{g}(n) = \frac{\bar{\mathbf{g}}(n)}{\bar{\alpha}(n)}$$

$$\mathbf{P}(n) = \lambda^{-1} \mathbf{P}(n-1) - \mathbf{g}(n) \bar{\mathbf{g}}^H(n)$$

Filtering

$$e(n) = y(n) - \mathbf{w}^H(n-1) \mathbf{x}(n)$$

Coefficient updating

$$\mathbf{w}(n) = \mathbf{w}(n-1) + \mathbf{g}(n) e^*(n)$$

Enfoque del trabajo

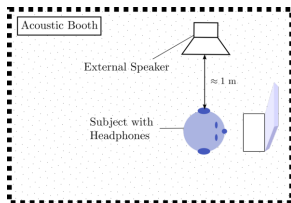
Realizaremos el análisis e implementación del algoritmo FxLMS y FxRLS aplicado a ANC, utilizando interferencias de entrada sintéticas.

Problemas a resolver

- Estabilidad
- Estimación de $\hat{S}(z)$
- Velocidad de convergencia vs desajuste
- ...

Datasets

Paths for Active Noise Cancellation Database



Biblioteca PyRoom Acoustics

